Proyecto Final de Probabilidad: Regresión de Poisson en Datos de Bikeshare

Carlos Zárate, Naiceyni Blanco

5 de abril de 2026

1. Introducción

El presente proyecto aborda el modelado del conteo de bicicletas rentadas en un sistema de transporte urbano utilizando técnicas de estadística aplicada. La distribución de Poisson constituye un pilar fundamental en la teoría de la probabilidad para modelar el número de ocurrencias de un evento discreto. A diferencia de las variables continuas, el número de usuarios (Y) es una variable aleatoria de conteo que toma valores en los enteros no negativos $\{0, 1, 2, \dots\}$. Dado que este fenómeno representa eventos independientes en un intervalo de tiempo continuo, la distribución de Poisson constituye el pilar fundamental para su análisis. Matemáticamente, si una variable aleatoria Y sigue una distribución de Poisson, la probabilidad de observar exactamente y eventos está dada por su función de masa de probabilidad:

$$P(Y = y) = \frac{e^{-\lambda}\lambda^y}{y!}$$

donde el parámetro $\lambda > 0$ representa la tasa promedio de ocurrencia o valor esperado, es decir ($E[Y] = \lambda$). En los escenarios probabilísticos clásicos, este parámetro suele asumirse como una constante fija para un intervalo determinado.

El Problema de la Tasa Variable

Sin embargo, en aplicaciones prácticas como el análisis del sistema de bicicletas compartidas (Bikeshare de Washington, D.C.), la suposición de una tasa constante resulta insuficiente y poco realista. La demanda de bicicletas no es un fenómeno estático; la tasa real, λ_i, varía dinámicamente dependiendo de múltiples factores externos identificados como covariables predictoras X_i

(tales como la temperatura, la hora del día y las condiciones climáticas). Si estas covariables no se integran de manera adecuada, el modelo producirá estimaciones sesgadas y desfavorables.

El Modelo Lineal Generalizado (Fusion Teorico-Práctico)

Para adaptar la teoría probabilística a este conjunto de datos, se implementa un Modelo Lineal Generalizado (GLM) conocido como Regresión de Poisson. El desafío principal al predecir conteos es evitar resultados físicamente imposibles (valores negativos). Para garantizar matemáticamente que el valor esperado sea siempre estrictamente positivo, la Regresión de Poisson aplica una función de enlace logarítmica que relaciona las covariables con la tasa λ_i:

$$\ln(\lambda_i) = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} = X_i^T \beta$$

Al aplicar la función exponencial para despejar la tasa esperada, obtenemos la forma definitiva del modelo predictivo:

$$\lambda_i = \exp(X_i^T \beta)$$

El objetivo de este estudio, con base en este marco, tiene el objetivo de contrastar la eficacia de dos enfoques predictivos. Por un lado, se evaluará un modelo clásico de Regresión Lineal Múltiple para demostrar cómo su aplicación sobre datos de conteo discreto puede derivar en deficiencias metodológicas y resultados erróneos (tales como predicciones de alquileres negativos). Por otro lado, se implementará el modelo de Regresión de Poisson sobre el conjunto de datos Bikeshare para comprobar cómo su estructura matemática ofrece una solución robusta y coherente, permitiendo analizar de forma precisa cómo varía el número de alquileres según las alteraciones horarias y climáticas.

2. Metodología Computacional y Matemática

Siguiendo el texto de Luis Rincón, asumimos que la variable respuesta Y_i sigue una distribución de Poisson con parámetro λ_i:

$$P(Y_i = y_i) = \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!} \tag{1}$$

Donde el valor esperado es $E[Y_i] = \lambda_i$. En la regresión de Poisson, utilizamos una función de enlace logarítmica para conectar las covariables X_i con el

parámetro:

$$\log(\lambda_i) = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} \implies \lambda_i = e^{X_i \beta} \tag{2}$$

Esta transformación garantiza que $\lambda_i > 0$, una propiedad que la regresión lineal simple no posee. El ajuste del modelo se realizó mediante la maximización de la función de Log-Verosimilitud ($\ell(\beta)$):

$$\ell(\beta) = \sum_{i=1}^{n} [y_i(X_i\beta) - e^{X_i\beta} - \log(y_i!)] \tag{3}$$

El desarrollo computacional se llevó a cabo en **Python 3.11**, utilizando la librería `statsmodels` para el ajuste de GLM y `pandas` para el manejo de datos.

3. Análisis Exploratorio (Resultados I)

El análisis visual de los datos reveló una distribución de la variable *bikers* con una marcada asimetría a la derecha, característica típica de procesos de Poisson donde los valores bajos son frecuentes y los eventos masivos son menos probables. Se observó una correlación positiva clara entre la temperatura y el volumen de rentas, así como fluctuaciones estacionales según la hora del día (hr).

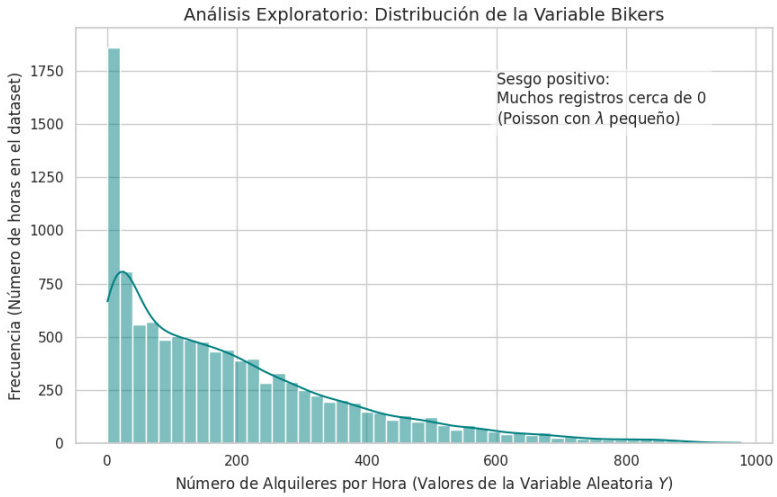

Figura 1: Histograma de la variable aleatoria de conteo *bikers*. La alta frecuencia de valores cercanos a cero coincide con los periodos de baja demanda documentados en el dataset.

4. Modelado y Comparación (Resultados II)

Se comparó el modelo de Regresión Lineal Múltiple (OLS) frente al GLM de Poisson. Los resultados principales se resumen a continuación:

- **Falla del Modelo Lineal:** Aunque a nivel agregado el modelo lineal parece seguir la tendencia, el análisis de residuos revela que en condiciones de baja demanda, el modelo OLS arroja valores negativos (518 instancias), invalidando su uso físico.

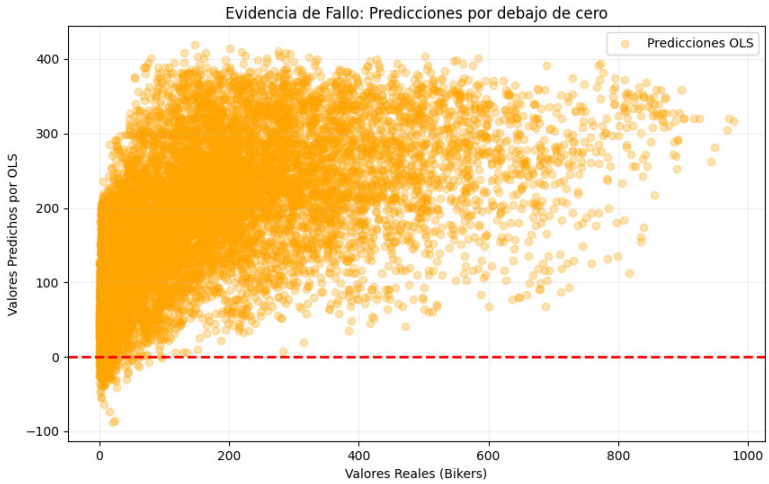

Figura 2: Evidencia de fallo en OLS: Predicciones por debajo de cero.

- **Consistencia de Poisson:** El modelo de Poisson, al utilizar el enlace exponencial, produjo predicciones estrictamente positivas. El valor de *Log-Likelihood* obtenido fue de $-4{,}201 \times 10^5$.

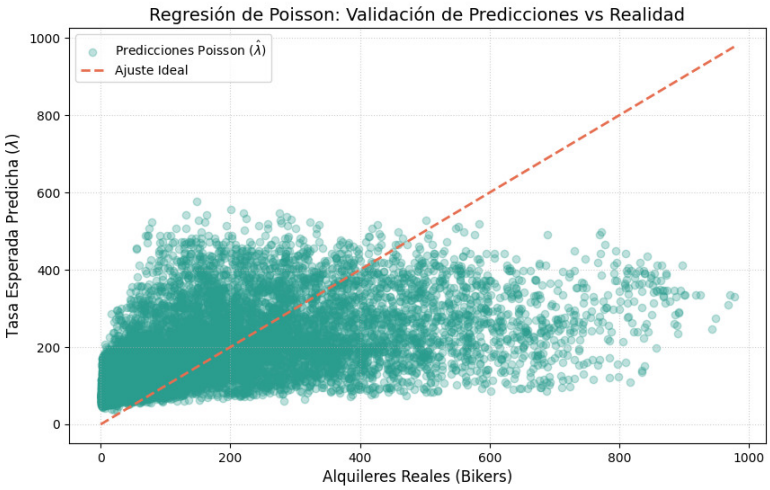

Figura 3: Validación del modelo de Poisson: Valores reales vs. predicciones positivas.

4.1. Procedimiento de Estimación de Coeficientes

Debido a que las ecuaciones de normalidad de la regresión de Poisson son no-lineales, los coeficientes no se obtienen por despeje algebraico, sino por un proceso iterativo de optimización numérica. El valor final de 0.0526 para la temperatura es el punto de convergencia donde se maximiza la probabilidad global de los datos observados. Después de tener los valores mediante Estimación por Máxima Verosimilitud, tenemos el siguiente recuadro:

Variable	Coeficiente (β)	Efecto Multiplicativo (e^{β})
Temperatura (temp)	0.0526	1.0540
Clima (weathersit)	-0.0384	0.9623
Día Laboral (workingday)	-0.0125	0.9875

Cuadro 1: Interpretación de coeficientes del modelo de Poisson.

Interpretación de coeficientes: De acuerdo con los resultados del Cuadro 1, se observa que la temperatura tiene un impacto positivo; específicamente, por cada grado Celsius adicional, la tasa esperada de rentas aumenta un 5,4 %. Por otro lado, el coeficiente del clima ($weathersit$) indica que condiciones meteorológicas más severas reducen la tasa esperada de alquileres en un 3,77 %, reflejando el efecto multiplicativo característico del enlace logarítmico del modelo de Poisson.

5. Conclusiones

El presente estudio permitió contrastar la eficacia de dos enfoques estadísticos para el modelado de conteos en sistemas de transporte urbano. Tras el análisis de los resultados, se derivan las siguientes conclusiones principales:

La Regresión de Poisson demostró ser el marco teórico adecuado para este conjunto de datos. Mientras que la regresión lineal tradicional genera inconsistencias matemáticas, como la predicción de alquileres negativos durante periodos de baja demanda (ej. madrugadas con clima adverso), el uso de la función de enlace logarítmica garantizó estimaciones coherentes y siempre positivas ($\lambda_i > 0$).

A diferencia de los modelos aditivos, en la Regresión de Poisson los coeficientes actúan de manera exponencial sobre la tasa de renta. Se determinó que la temperatura es el factor de mayor influencia positiva; un incremento en esta variable no solo suma usuarios, sino que multiplica la tasa esperada de alquileres.

El impacto de las condiciones externar, el modelo capturó con precisión cómo las condiciones climáticas desfavorables y los días no laborales actúan como "frenos.^en la tasa de ocurrencia. Por el contrario, las horas pico de transporte (variables hr) concentran la mayor densidad de eventos, lo que confirma que el parámetro λ es altamente sensible al contexto temporal.

La transición de una distribución de Poisson teórica a una implementación de Machine Learning permite a los gestores de Bikeshare realizar previsiones logísticas precisas. Entender que el fenómeno sigue una estructura de conteo discreto permite optimizar la disponibilidad de bicicletas basándose en la probabilidad real de demanda y no en promedios lineales simplistas.

6. Anexo - Repositorio de Código

El código fuente, el conjunto de datos *Bikeshare.csv* y los scripts de generación de gráficas utilizados en este proyecto están disponibles para su consulta y reproducibilidad en el siguiente repositorio de GitHub:

`https://github.com/CarlosZs4/Regresi-n-de-Poisson-en-Datos-de-Bikeshare`

El repositorio incluye un readme.txt sobre las instrucciones necesarias para ejecutar el modelo GLM de Poisson presentado en este informe.